Informe Ejecutivo: Sistema Automatizado de Valoración de Viviendas en Producción

Preparado por: Daniel Humberto Llanos Llanos

Objetivo del Proyecto: Desarrollar y desplegar un servicio inteligente capaz de estimar el precio de mercado de una vivienda en tiempo real, garantizando alta precisión estadística, control de calidad en los datos de entrada y portabilidad total para operar en cualquier servidor.

1. Resumen Ejecutivo

Se construyó de principio a fin una solución analítica lista para producción que estima el valor de venta de inmuebles residenciales en dólares (USD). A partir de una base histórica de 1,460 propiedades, se entrenó un modelo predictivo que logra explicar el 91.6% de la variación real de los precios en viviendas nuevas no vistas durante su entrenamiento.

La solución final no se queda en un análisis teórico: fue empaquetada, blindada contra errores de digitación, transformada en un servicio web de consulta inmediata (API) y alojada dentro de un contenedor ligero (Docker) que garantiza su funcionamiento continuo.

2. Selección Estratégica de Datos

El archivo base del proyecto (viviendas.csv) cuenta con 1,460 viviendas registradas. En lugar de sobrecargar el sistema con decenas de variables irrelevantes, se aplicó un criterio de selección enfocado en las 12 características clave que determinan el valor real de un inmueble:

- 8 variables de dimensión y estructura: Calidad general de construcción (escala 1 a 10), área habitable, área de sótano, superficie total del terreno, capacidad de cochera, número de baños completos, año de construcción y año de remodelación.
- 4 variables de equipamiento y ubicación: Calidad de cocina, calidad de acabados exteriores, presencia de aire acondicionado central y vecindario.

Para asegurar una evaluación honesta y rigurosa, los datos se dividieron en dos grupos: 80% (1,168 viviendas) para entrenar al sistema y 20% (292 viviendas) reservadas exclusivamente para poner a prueba el modelo con casos que nunca antes había visto.

3. Elección del Modelo Ganador

Se entrenaron y compararon tres algoritmos distintos utilizando exactamente las mismas 292 viviendas de prueba. Los resultados determinaron de manera objetiva al modelo ganador:

Modelo Evaluado	Precisión Explicativa (R2)	Error Medio Absoluto (MAE)	Error Cuadrático (RMSE)	Veredicto Ejecutivo
Regresión Lineal (Ridge)	84.9%	$20,895 USD	$34,021 USD	Descartado: insuficiente para captar plusvalías complejas.

Random Forest	89.7%	$17,846 USD	$28,150 USD	Competitivo, pero con mayor margen de desviación.
Gradient Boosting (Ganador)	91.6%	$16,588 USD	$25,348 USD	Seleccionado: Mayor precisión y menor margen de error.

Por qué ganó Gradient Boosting: Es el modelo más preciso del estudio (alcanza un 91.6% de ajuste en casos nuevos) y reduce el error promedio en más de $4,300 USD por propiedad frente al modelo base tradicional.

4. Empaquetado, Auditoría y Control de Calidad

Para llevar este modelo del laboratorio a la operación diaria sin riesgo de fallas, se ejecutaron tres controles de ingeniería:

1. Empaquetado integral (Bundle): Se guardó en un único archivo maestro (modelo_bundle_viviendas.joblib) todo el flujo de transformación y predicción junto con su ficha de auditoría (variables utilizadas, rangos permitidos, métricas oficiales, fecha exacta de entrenamiento y versiones del software).
2. Prueba de integridad: Antes de conectarlo al sistema web, se recargó el archivo guardado y se comprobó matemáticamente que sus estimaciones fueran 100% idénticas a las del entrenamiento original (arrojando exactamente $139,223.61 USD en la vivienda de control).
3. Filtro automático contra datos erróneos (esquemas.py): Se programó un contrato de validación que revisa cada solicitud antes de que llegue al modelo. Si un usuario ingresa un dato ilógico (por ejemplo, una calidad de 99 en una escala del 1 al 10, o un vecindario inexistente), el sistema rechaza la solicitud de inmediato devolviendo una alerta controlada (Código 422) y protegiendo la estabilidad del servicio.

5. Despliegue como Servicio Web y Contenedorización

Finalmente, el modelo se integró en una aplicación web rápida (main.py) que ofrece tres puntos de consulta:

- Consulta de Estado (GET /): Confirma en tiempo real que el servidor está activo y operativo.
- Ficha Técnica (GET /info): Expone de forma transparente las métricas de desempeño, la fecha de entrenamiento y las reglas vigentes del modelo.
- Cotizador en Línea (POST /predecir): Recibe las 12 características de una propiedad y devuelve al instante su precio estimado en dólares (Código 200 OK).

Listo para cualquier entorno (Docker): Toda la solución fue encapsulada en un contenedor independiente (Dockerfile sobre una versión ligera de Python). Esto garantiza que el sistema pueda trasladarse y encenderse en segundos en cualquier computador o servidor en la nube de la organización, manteniendo exactamente el mismo rendimiento y precisión verificados en las pruebas.

Enlace del proyecto publicado en GitHub:

https://github.com/Sanmarquino/despliegue---final--modelo-viviendas